

Filière : SDBDIA 2ème année

Fine-tuning d'un Small Language Model pour la Génération de Résumés à partir de Données Tabulaires/textuel

Rapport d'avancement de stage

Réalisé par:

Youssef Aitbouddroub

1. Contexte et objectif du stage

Ce stage porte sur la génération automatique de texte à partir de tableaux : Fine-tuning d'un Small Language Model pour la Génération de Résumés à partir de Données Tabulaires/textuel, l'objectif est de produire automatiquement une phrase en langage naturel qui résume l'information sélectionnée. Cette tâche s'appuie sur le jeu de données ToTTo, une référence académique dans ce domaine.

Le travail réalisé jusqu'à présent se décompose en deux grandes étapes :

- Étape 1 : comparer plusieurs modèles de langue légers (SLM) afin de choisir le plus adapté à la tâche.
- Étape 2 : fine-tuner le modèle retenu sur le jeu de données ToTTo, puis évaluer le gain de performance obtenu.

2. Étape 1 : Sélection du modèle de base

2.1 Méthodologie

Avant de se lancer dans un fine-tuning coûteux en temps de calcul, trois modèles candidats ont été évalués à froid; sans aucun entraînement supplémentaire; sur un échantillon de 300 exemples tirés de l'ensemble de validation de ToTTo :

- FLAN-T5 Small (~80M de paramètres)
- FLAN-T5 Base (~250M de paramètres)
- mT5 Small (~300M de paramètres, modèle multilingue)

Pour chaque modèle, un prompt structuré est construit à partir du tableau (titre, section, en-têtes de colonnes, cellules mises en évidence), puis le modèle génère une phrase de résumé. Quatre métriques automatiques sont utilisées pour comparer la qualité des résumés générés à la phrase de référence rédigée par un humain :

- ROUGE-L : mesure le recouvrement de la plus longue sous-séquence commune avec la référence.
- METEOR : mesure de recouvrement de mots plus tolérante (synonymes, racines de mots).
- BERTScore : similarité sémantique calculée à partir de représentations vectorielles (embeddings).
- PARENT : métrique spécifique aux tableaux, qui vérifie que le résumé reste fidèle aux données réellement présentes dans le tableau.

Un score composite (moyenne des quatre métriques) est ensuite calculé pour classer les modèles.

2.2 Résultats

Modèle	ROUGE-L	METEOR	BERTScore	PARENT	Score composite
FLAN-T5 Base	0.368	0.374	0.812	0.375	0.482
FLAN-T5 Small	0.324	0.329	0.788	0.332	0.443
mT5 Small	0.005	0.034	0.567	0.001	0.152

Scores compris entre 0 et 1 ; plus la valeur est élevée, meilleure est la performance.

2.3 Conclusion de l'étape 1

FLAN-T5 Base obtient le meilleur score sur les quatre métriques et sur le score composite. mT5 Small, bien que plus volumineux, obtient des résultats très faibles : ce modèle, orienté multilingue, est probablement mal adapté à une tâche de résumé en anglais avec un prompt de ce type sans fine-tuning préalable. FLAN-T5 Base représente le meilleur compromis entre qualité des résumés et taille du modèle (donc coût de calcul et de mémoire), c'est pourquoi il a été retenu pour la suite du stage.

3. Étape 2 : Fine-tuning du modèle avec LoRA

Le fine-tuning complet d'un modèle comme FLAN-T5 Base nécessiterait de ré-entraîner ses 250 millions de paramètres, ce qui est coûteux en mémoire GPU. La technique LoRA (Low-Rank Adaptation) permet de contourner ce problème : au lieu de modifier tous les poids du modèle, on insère de petites matrices supplémentaires, entraînaibles, à l'intérieur des couches d'attention, et seules ces matrices sont mises à jour pendant l'entraînement. Le modèle de base reste figé.

3.1 Configuration retenue

- Modèle de base : google/flan-t5-base
- Paramètres LoRA : rang $r = 8$, facteur d'échelle $\alpha = 16$, appliqués aux projections d'attention (q, v)
- Paramètres entraînaibles : environ **885 000** sur 248 millions, soit seulement 0,36 % du modèle
- Taux d'apprentissage (learning rate) : 1×10^{-4} , planification cosinus avec **500** pas de préchauffe
- Précision de calcul : **bfloat16** (adaptée au GPU utilisé)
- Matériel : PC personnel, GPU RTX 3060 (12 Go de VRAM)
- Durée d'entraînement : environ **2h47**, sur **3** époques

3.2 Difficultés rencontrées et résolutions

L'entraînement n'a pas fonctionné du premier coup : deux problèmes distincts ont dû être diagnostiqués et corrigés, ce qui a représenté une part importante du travail de cette étape.

- Problème 1 : Perte égale à « NaN » (valeur non numérique) : la première configuration chargeait le modèle en précision bfloat16 mais utilisait un entraînement en précision float16, deux formats incompatibles pour ce modèle. Cette incohérence provoquait un dépassement de capacité numérique. Correction : aligner la précision d'entraînement sur celle du modèle (bfloat16 partout).
- Problème 2 : Instabilité liée à LoRA : après correction du premier problème, la perte restait « NaN ». L'origine était cette fois un facteur d'échelle LoRA trop élevé combiné à un taux d'apprentissage trop important, ce qui provoquait une explosion des gradients.

Correction : réduction du facteur d'échelle LoRA et du taux d'apprentissage.

Un test de cohérence (calcul de la perte sur un lot de données avant tout entraînement) a permis de confirmer que le problème venait bien de l'optimisation et non des données, en isolant précisément la cause.

3.3 Résultats de l'entraînement

Une fois ces corrections apportées, l'entraînement s'est déroulé normalement sur les 3 époques prévues, sans nouvelle instabilité :

Époque	Perte d'entraînement	Perte de validation
1	2.235	1.635
2	2.164	1.594
3	2.362	1.588

La perte de validation diminue régulièrement et se stabilise en fin d'entraînement, ce qui indique un apprentissage réussi sans sur-apprentissage (overfitting).

3.4 Comparaison avant / après fine-tuning

Pour mesurer l'apport réel du fine-tuning, le modèle spécialisé a été comparé au modèle de base (non entraîné) sur le même échantillon de validation, en utilisant des métriques de génération de texte :

Métrique	Modèle de base	Modèle fine-tuné	Évolution
ROUGE-L	0.201	0.378	$\approx \times 1,9$
BLEU	0.060	0.167	$\approx \times 2,8$
METEOR	0.203	0.392	$\approx \times 1,9$
BERTScore-F1	0.860	0.903	+ 0,043

Ces résultats montrent une amélioration nette et cohérente sur l'ensemble des métriques. Les métriques ROUGE-L, BLEU et METEOR, qui mesurent la ressemblance textuelle avec la référence, progressent fortement : le modèle fine-tuné a bien appris le format attendu (une seule phrase, centrée sur les cellules mises en évidence). La progression plus modeste du BERTScore, qui mesure la similarité de sens plutôt que la forme exacte, s'explique par le fait que le modèle de base produit déjà des phrases globalement cohérentes sur le plan sémantique, mais mal alignées avec le format et le contenu exact attendus. Cette combinaison confirme que le fine-tuning a bien permis au modèle d'apprendre la tâche spécifique, et pas seulement à mieux « écrire ».

4. Conclusion et prochaines étapes

À ce stade du stage, deux objectifs ont été atteints : la sélection justifiée d'un modèle de base (FLAN-T5 Base) par un benchmark comparatif, puis son adaptation réussie à la tâche de résumé de tableaux via un fine-tuning LoRA, avec un gain de performance mesuré et documenté par rapport au modèle non entraîné.

Les prochaines étapes envisagées sont :

- Expérimenter d'autres techniques de fine-tuning, notamment QLoRA (quantification du modèle en 4 bits combinée à LoRA), afin de comparer le compromis performance / consommation mémoire par rapport à l'approche LoRA actuelle.
- Une évaluation qualitative : relire manuellement un échantillon de résumés générés pour vérifier leur exactitude factuelle par rapport au tableau source.
- L'augmentation de la longueur maximale des séquences en entrée (actuellement environ la moitié des exemples sont tronqués), afin de mieux couvrir les tableaux les plus longs.
- Le calcul d'une métrique supplémentaire (BLEURT), plus proche du jugement humain, pour confirmer les résultats obtenus.