

Filière : SDBDIA 2ème année

Fine-tuning d'un Small Language Model pour la Génération de Résumés à partir de Données Tabulaires/textuel

Rapport d'avancement de stage 3

Réalisé par:

Youssef Aitbouddroub

1. Contexte et objectif de cette étape

Après la phase de fine-tuning du modèle **FLAN-T5 Base** à l'aide des techniques **LoRA** et **QLoRA**, l'objectif de cette étape était d'évaluer les performances réelles du modèle sur des données de test et d'identifier les causes des erreurs observées afin d'orienter les prochaines expérimentations.

Travaux réalisés:

Les principales étapes réalisées sont les suivantes :

- préparation du dataset ToTTo sous forme *Prompt - Target* ;
- fine-tuning du modèle avec LoRA puis QLoRA ;
- comparaison des deux techniques à l'aide de plusieurs métriques (ROUGE, BLEU, METEOR, BERTScore, etc.) ;
- test du modèle sur plusieurs tableaux provenant de trois domaines différents (finance, médical et ventes) afin d'évaluer sa capacité de généralisation.

Résultats obtenus:

Les métriques automatiques obtenues après le fine-tuning montrent une amélioration par rapport au modèle de base.

Cependant, lors des tests sur de nouveaux tableaux, les résultats restent insuffisants :

- Certaines informations importantes sont ignorées ;
- Plusieurs réponses contiennent des hallucinations ;
- Les résumés produits sont parfois incomplets ou peu pertinents lorsque le tableau devient plus complexe.

Ces observations montrent que de bonnes métriques d'évaluation ne garantissent pas forcément une bonne qualité de génération sur des données réelles.

2. Analyse des causes possibles

Plusieurs investigations ont été réalisées afin d'identifier l'origine de ces limitations.

2.1 Limitation de la longueur des séquences

L'analyse du dataset ToTTo a montré qu'environ **40 %** des exemples dépassent la limite de **512 tokens** supportée par FLAN-T5 Base. De plus, l'entraînement premier a été effectué sur une limite de **384 tokens** pour optimiser le temps d'entraînement puisqu'il s'agit simplement de la première itération d'entraînement, l'objectif est d'avoir une idée des performances du modèle après la phase de fine-tuning.

```
[transformers] Token indices sequence length is longer than the specified maximum sequence length for this model (566 > 512).
<=256 : 0.3599589271370724
<=320 : 0.44387674828794066
<=384 : 0.5077053022084944
<=448 : 0.5625988522784674
<=512 : 0.6106855690164871
```

Dans ces cas, une partie du tableau qui dépasse la limite est supprimée lors de la tokenisation. Cela signifie que le modèle peut être entraîné sans voir toutes les informations nécessaires à la génération de la phrase cible. Cette limitation est probablement l'une des principales causes des erreurs observées.

2.1 Limitation du dataset Totto

Le dataset ToTTo n'est pas un véritable dataset de résumé de tableaux.

Chaque exemple demande de générer une phrase décrivant uniquement des cellules préalablement sélectionnées (highlighted cells).

Le modèle apprend donc principalement à transformer une information déjà ciblée en phrase naturelle.

En revanche, dans le cadre du stage, le comportement attendu est différent :

fournir un tableau complet au modèle et lui demander d'identifier automatiquement les informations importantes avant de produire un résumé.

Il existe donc un écart entre la tâche d'entraînement et l'objectif final du projet.

2.3 Capacité du modèle

FLAN-T5 Base reste un modèle relativement compact (≈ 250 millions de paramètres).

Même après fine-tuning, sa capacité à comprendre des tableaux volumineux ou complexes semble limitée.

Les hallucinations observées peuvent être liées à cette capacité de représentation, en plus des limitations du dataset.

3. Pistes d'amélioration identifiées

Plusieurs solutions potentielles ont été identifiées :

- Reconstruire le dataset en conservant uniquement les exemples dont la longueur reste inférieure à 512 tokens (environ 60 % de la longueur du dataset d'origine) ;
- Relancer le fine-tuning sur ce nouveau dataset afin de mesurer l'impact réel de la troncature ;
- Etudier des datasets plus adaptés au résumé de tableaux complets ;

4. Conclusion

Les expérimentations montrent que les techniques de fine-tuning (LoRA et QLoRA) fonctionnent correctement et permettent d'améliorer les performances du modèle.

Cependant, les principales limitations semblent désormais provenir de la combinaison :

- des contraintes de longueur du modèle (512 tokens) ;
- des caractéristiques du dataset ToTTo ;
- de la différence entre la tâche apprise pendant l'entraînement et le besoin réel du projet.

À ce stade, il semble pertinent de valider avec l'encadrant la direction à suivre avant de lancer de nouvelles expérimentations longues (plusieurs heures de réentraînement), notamment afin de déterminer s'il est préférable :

- de poursuivre l'étude en reconstruisant le dataset et en relançant le fine-tuning ;
- ou d'explorer une autre approche (dataset ou modèle) plus adaptée à la génération automatique de résumés de tableaux.